


Análise da extração de dados

Dataset: <https://archive.ics.uci.edu/dataset/109/wine>


- **Boxplot sem normalização**



Como podemos observar, a maioria dos features apresenta uma distribuição uniforme das amostras. Algumas exceções são as features de ácido málico, flavonoides e prolina.


As features ácido málico, magnésio, proantocianidinas, intensidade da cor, e matiz possuíram apenas outliers superiores; enquanto as features cinzas e alcalinidade das cinzas apresentaram ambos os tipos de outliers.

- **Boxplot com normalização**



A partir da normalização, verificamos que os valores se distribuíram por volta de -2 e 2. Por causa dos outliers, alguns gráficos apresentam em sua escala valores como -2.5 e 2.5 no eixo Y, mas o boxplot em momento algum os ultrapassa.

- Distribuição dos elementos por classe**




Conforme o próprio documento do dataset nos informa, observamos a seguinte distribuição de elementos:

- Classe 1: 59 elementos
- Classe 2: 71 elementos
- Classe 3: 48 elementos

Há uma certa discrepância entre a quantidade de elementos da classe 2 e da classe 3, que possivelmente pode nos levar a desafios na análise com *Machine Learning*.

- Matriz de correlação



Pela matriz de correlação, podemos extrair algumas relações entre as features.

A correlação mais forte indicada pela tabela é entre o total de fenóis e a quantidade de flavonoides na bebida. Podemos facilmente verificar que essa correlação faz sentido, uma vez que flavonoides são fenóis propriamente ditos.


Outras correlações positivas que valem o destaque são:

- Flavonoides e OD280/OD315 de vinhos diluídos, com score 0.8

- Total de fenóis e OD280/OD315 de vinhos diluídos, com score 0.7
- Proantocianidinas e flavonoides, com score 0.7

Já para as correlações negativas, não observou-se nenhum valor relevante, sendo o mais alto -0.6, entre ácido málico e matiz.

- **PCA**



Através do PCA, podemos analisar uma clusterização forte de cada classe. Poucas amostras de diferentes classes se misturam, o que torna a análise posterior com técnicas de *ML* mais simples.